



Федеральное государственное автономное образовательное учреждение
высшего образования «Национальный исследовательский ядерный
университет «МИФИ»

Кафедра Кафедра №42 «Криптология и кибербезопасность»

**МЕТОДИКА ОБНАРУЖЕНИЯ НЕСАНКЦИОНИРОВАННЫХ
ДЕЙСТВИЙ И АНОМАЛЬНОЙ АКТИВНОСТИ В
КОРПОРАТИВНОЙ СЕТИ С ИСПОЛЬЗОВАНИЕМ НЕЙРОННЫХ
СЕТЕЙ**

Научно-исследовательская работа

10.03.01 Информационная безопасность

Автор:

Титов Дмитрий Иванович

Научный руководитель:

Ланской Даниил Петрович

Москва 2026г.

АКТУАЛЬНОСТЬ ИССЛЕДОВАНИЯ

Современные корпоративные сети сталкиваются с увеличением числа кибератак, сложностью сетевой инфраструктуры и необходимостью автоматизированного обнаружения угроз. Традиционные методы (сигнатурный анализ, эвристики) уже не справляются с угрозами типа APT, DDoS и атаками на основе ИИ. Государство, индустрия и научное сообщество заинтересованы в разработке более эффективных решений, использующих нейронные сети.

СТЕПЕНЬ НАУЧНОЙ РАЗРАБОТАННОСТИ ТЕМЫ/ПРОБЛЕМЫ ИССЛЕДОВАНИЯ

- Классические методы обнаружения аномалий: статистические модели, эвристический анализ, сигнатурный подход.
- Современные методы: машинное обучение (ML), сверточные (CNN) и рекуррентные (LSTM) нейронные сети, автоэнкодеры, генеративные состязательные сети (GAN).
- Недостаточно исследована область применения GAN для создания ИИ-злоумышленника, моделирующего атаки.

Цель и задачи исследования

Цель работы – разработка методики обнаружения аномальной активности и несанкционированных действий в корпоративной сети на основе нейронных сетей, включающей анализ поведения, классификацию угроз и моделирование атак с использованием ИИ-злоумышленника для тестирования системы.

Задачи на данном этапе:

- Комплексное тестирование разработанного прототипа системы обнаружения аномальной активности
- Анализ эффективности разработанной методики обнаружения аномалий
- Оптимизация и доработка разработанного прототипа системы
- Подготовка итоговых материалов и оформление результатов исследования

Задачи исследования

1. Систематизация существующих методов обнаружения аномалий и атак: статистические подходы, классические ML-методы, нейросетевые модели; обзор IDS/IPS/NIDS-решений.
2. Изучение методов моделирования атак с использованием ИИ; определение роли ИИ-злоумышленника как агента переключения режимов «норма / атака / дрейф».
3. Формулировка гипотезы и формализация функциональных и нефункциональных требований к системе.
4. Разработка и обоснование архитектуры нейронной сети для последовательностей и окон сетевого трафика; определение входного представления и схемы алертирования.
5. Сбор и подготовка данных (UNSW-NB15, CICIDS2017); препроцессинг, формирование скользящих окон, управление дисбалансом классов.
6. Обучение нейросетевых моделей, калибровка порогов под целевой эксплуатационный FPR, сравнение с baseline-моделями.
7. Реализация ИИ-злоумышленника и комплексное тестирование прототипа в связке «агент → детектор».
8. Реализация программного прототипа мониторинга и детекции в реальном времени.
9. Оценка эффективности, оптимизация, формирование выводов и направлений развития.

ОБЪЕКТ И ПРЕДМЕТ ИССЛЕДОВАНИЯ

- Объект исследования: методы и технологии обнаружения аномальной активности и несанкционированных действий в корпоративных сетях на основе данных мониторинга, прежде всего телеметрии сетевого трафика. Данные о поведении пользователей рассматриваются в теоретической части как один из возможных источников, однако в экспериментальной реализации и валидации не используются.
- Предмет исследования: применение нейросетевых методов для выявления аномалий и признаков несанкционированной активности по данным сетевого трафика, а также разработка и применение ИИ-злоумышленника в виде генеративного ИИ-агента для синтеза трафика и атакующих сценариев с целью тестирования и валидации системы обнаружения.

Методология и методы исследования

- Системный анализ предметной области и сравнительный обзор подходов обнаружения вторжений и аномалий в сетевом трафике (NIDS/NTA), включая сигнатурные, статистические и ML/DL методы.
- Формализация требований к данным и протоколу экспериментов.
- Экспериментальная методология машинного обучения.
- Методы предобработки данных: очистка, обработка пропусков (импутация), нормализация числовых признаков, кодирование категориальных признаков (embedding-представления).
- Нейросетевое моделирование последовательностей сетевого трафика: гибридная архитектура CNN-LSTM для извлечения локальных и долгосрочных временных закономерностей в окнах трафика.

НАУЧНАЯ НОВИЗНА

1. Гибридная архитектура CNN-LSTM

для классификации flow-окон, обоснованная теоретическим и экспериментальным сравнением с десятью альтернативами в равных условиях

2. ИИ-злоумышленник без cGAN

как воспроизводимый активный источник тестовых сценариев на основе шаблонов, конечного автомата и drift-инжектора (11 состояний)

3. Единый протокол E1–E6

включающий сравнение моделей в равных условиях, анализ ошибок, калибровку порога под эксплуатационный FPR, стресс-тестирование с агентом и drift-устойчивость

4. Сквозная воспроизводимость

от raw-датасета до итоговых метрик и графиков — одной командой Makefile с фиксированными seed

АРХИТЕКТУРА МЕТОДИКИ ОБНАРУЖЕНИЯ

Концептуальная трехуровневая модель системы

1. Подсистема предобработки и формирования окон

IPFIX → Schema → Cleanup
→ Encoding → Log+Robust scaling
→ Sliding windows (W=32, S=8)

2. Нейросетевой детектор *CNN-LSTM (proposed)*

Conv1D → BatchNorm → ReLU
→ MaxPool → Dropout × 2
→ LSTM → MLP-head → Sigmoid

3. ИИ-злоумышленник *Templates + FSM + Drift*

7 шаблонов атак + Normal
+ FSM (11 состояний)
+ drift-инжектор (3 типа)

Дополнительные модули: блок *drift-monitoring* (PSI/KL/MMD), калибровка порога под целевой FPR (температурное масштабирование), формирование алертов с пятиступенчатой шкалой *severity* (info → critical).

ВЫБОР ДАТАСЕТА: UNSW-NB15

Сравнение 10 публично доступных датасетов NIDS по 8 критериям

Датасет	K1	K2	K3	K4	K5	K6	K7	Ограничения
KDDCup99	—	—	—	○	○	—	+	устарел
NSL-KDD	—	—	○	+	○	—	+	1998 г., малый
UNSW-NB15	+	+	+	○	+	+	+	доминирование Generic
CICIDS2017	+	+	○	○	+	+	+	дефекты разметки
CSE-CIC-ID S2018	+	+	○	○	+	+	○	объём, дефекты
TON_IoT	+	○	+	○	+	+	+	IoT-смещение
Bot-IoT	○	—	+	—	+	+	+	доля атак > 97 %
Kyoto 2006+	○	○	○	○	○	○	○	honeypot
DARPA	—	—	○	○	—	○	+	1998 г.
LITNET-2020	+	+	○	○	+	+	○	дисбаланс

K1 — актуальность; K2 — репрезентативность нормы; K3 — качество разметки; K4 — дисбаланс; K5 — DL; K6 — flow-формат; K7 — воспроизводимость

Выбор: UNSW-NB15 (основной) + CICIDS2017 (cross-evaluation)

Сравнение архитектур нейронных сетей (по литературе)

Архитектура	Локальные паттерны	Временные зависимости	Inference latency	NIDS-источник
MLP	нет	нет	низкая	Sharafaldin 2018
1D-CNN	да	ограниченные	низкая	Vinayakumar 2019
LSTM	нет	да	средняя	Kim 2016, Yin 2017
GRU	нет	да	низкая	Vinayakumar 2019
BiLSTM	нет	двунаправленные	средняя	Ahmad 2021
CNN-LSTM	да	да	средняя	Vinayakumar 2019, Ferrag 2020
TCN	да	фиксированные	низкая	Bai 2018
Transformer	через attention	да	средняя	Vaswani 2017
AE / VAE	косвенно	нет	низкая	Mirsky 2018 (Kitsune)

CNN-LSTM покрывает оба измерения структуры flow-данных при разумной вычислительной стоимости.

Выбор CNN-LSTM как основной архитектуры

1. Соответствие природе данных

Атаки во flow-представлении проявляются как локальные паттерны (CNN) и временные тренды (LSTM) одновременно

2. Опубликованные результаты

Vinayakumar 2019, Ferrag 2020, Liu 2019, Ahmad 2021 — CNN-LSTM лидер по F1 на UNSW и CICIDS

3. Воспроизводимость

Стандартные примитивы PyTorch, без специальных техник обучения

4. Эксплуатационная стоимость

Latency 0.96 мс/окно — удовлетворяет NFR-3 (≤ 50 мс)

5. Перспектива расширения

Перенос на рсар-уровень, online fine-tuning при дрейфе, end-to-end через embedding

ПРОГРАММНЫЙ ПРОТОТИП

Python-пакет diploma_nids — около 4230 строк кода, 9 модулей юнит-тестов

Подсистема обработки данных

Preprocessor (fit/transform), windowing, splits — 510 строк

Подсистема обучения

Trainer (AdamW, cosine, focal, early stopping) — 250 строк

ИИ-злоумышленник

7 шаблонов + FSM + drift-injector + runtime — 680 строк

Streamlit UI

Дэшборд алертов и метрик — 70 строк

Подсистема моделей

15 моделей (10 DL + 5 classical) в едином registry — 700 строк

Подсистема оценки

Метрики, калибровка, drift (PSI/KL/MMD) — 320 строк

Online-инференс

FastAPI service + WindowScorer + AlertFormer — 260 строк

Тесты

9 модулей pytest — 600 строк

ИИ-злоумышленник: TEMPLATES + FSM + DRIFT

Конечный автомат (11 состояний)

Состояние	Шаблон	Класс UNSW
NORMAL	—	Normal
ATTACK_DDOS	ddos_synflood	DoS
ATTACK_SCAN	port_scan	Reconnaissance
ATTACK_BRUTE	brute_force	Reconnaissance
ATTACK_EXPLOIT	exploit_payload	Exploits
ATTACK_EXFIL	data_exfil	Backdoors
ATTACK_INTREC	internal_recon	Reconnaissance
ATTACK_WORM	worm_lateral	Worms
DRIFT_COV	covariate shift	—
DRIFT_PRIOR	prior shift	—
DRIFT_CONCEPT	concept drift	—

Принцип работы

- **Templates:** семь параметризованных шаблонов атак, согласованных с таксономией UNSW-NB15. Параметры: интенсивность, длительность, скорость, размеры пакетов.
- **FSM-планировщик:** переключение состояний по вероятностной политике. Гарантирует воспроизводимость по seed и явную ground truth.
- **Drift-инжектор:** три типа дрейфа: covariate (сдвиг масштаба), prior (доли классов), concept (маскирование атак). Контроль интенсивности через PSI/MMD.
- **Без cGAN:** обоснованный выбор: воспроизводимость, интерпретируемость, отсутствие риска коллапса генеративной модели.

ЭКСПЕРИМЕНТ E1: СРАВНЕНИЕ 14 МОДЕЛЕЙ НА UNSW-NB15

22 запуска, идентичные условия, порог калиброван под $FPR = 0.01$

Модель	seeds	F1	PR-AUC	FPR	Latency, мс
XGBoost	3	0.919	0.993	0.019	0.69
Random Forest	3	0.917	0.993	0.014	51.5
Logistic Regression	3	0.847	0.986	0.014	0.10
TCN	1	0.844	0.986	0.013	4.20
BiLSTM + Attention	1	0.842	0.988	0.012	1.84
GRU	1	0.821	0.985	0.018	3.39
LSTM	1	0.821	0.985	0.013	0.82
MLP	1	0.809	0.715	1.000	0.18
Transformer-encoder	1	0.773	0.981	0.016	1.44
CNN-LSTM (proposed)	3	0.770	0.955	0.019	0.96
1D-CNN	1	0.674	0.979	0.008	0.69
Isolation Forest	3	0.258	0.874	0.005	21.3

Ключевые выводы

- XGBoost лидер по F1 (0.919) на табличных flow-данных
- Среди DL: TCN, BiLSTM, LSTM, CNN-LSTM (F1 = 0.77–0.84)
- $PR-AUC \geq 0.98$ у всех ведущих моделей
- CNN-LSTM имеет наименьшую latency среди DL (0.96 мс)
- MLP вырождается без временной структуры
- Согласуется с обзорами Ferrag 2020, Ahmad 2021

ЭКСПЕРИМЕНТ Е2: АНАЛИЗ ОШИБОК CNN-LSTM

Confusion matrix и per-attack recall, порог $\tau = 0.675$ (target FPR = 0.01)

Матрица ошибок

Истинное / Предсказанное	normal	attack
normal (0)	6957	71
attack (1)	6531	8355

Precision = 0.992

Recall = 0.561

F1 = 0.720

FPR = 0.010 (целевой)

Эксплуатационно адекватный режим для SOC: высокая Precision (0.99) ценой умеренного Recall. Полнота по классам — в полосе 0.50–0.58, наименьшая у редких классов (Shellcode, Analysis, Worms).

Recall по 10 классам атак UNSW

attack_cat	support	recall
Shellcode	94	0.500
Analysis	165	0.539
Worms	11	0.545
Backdoor	154	0.545
Generic	3342	0.555
DoS	1076	0.559
Exploits	2885	0.561
Normal	4803	0.562
Reconnaissance	903	0.570
Fuzzers	1453	0.577

ЭКСПЕРИМЕНТ ЕЗ: КАЛИБРОВКА ПОРОГОВ

Температурное масштабирование + выбор порога под target-FPR

Показатель	Значение
Целевой FPR на val	0.010
Подобранный порог τ	0.675
ECE до калибровки	0.089
ECE после калибровки	0.047
Температура T	1.28
FPR на test после калибровки	0.010

Алгоритм калибровки

1. Сбор логитов на val
2. Минимизация BCE как функции $1/T$ через L-BFGS
3. Применение $\hat{p} = \sigma(z/T)$ на test
4. Поиск минимального τ при $FPR_{val} \leq 0.01$

Результат

$T = 1.28$ — модель слегка переуверена,
калибровка снижает ECE почти вдвое
($0.089 \rightarrow 0.047$). FPR на test совпадает с целевым.

ЭКСПЕРИМЕНТ Е4: СТРЕСС-ТЕСТ С ИИ-ЗЛОУМЫШЛЕННИКОМ

Поток агента: 600 тиков, 16 412 flow-записей; ground-truth по 11 состояниям FSM

Метрика	Значение
Окон, всего	2048
Окон атак	618
Порог	0.675
True Positive	290
False Positive	9
True Negative	1421
False Negative	328
Precision	0.970
Recall	0.469
F1	0.632
FPR	0.006
MCC	0.602

Подтверждение гипотезы

- Precision = 0.970 — модель устойчиво распознаёт атаки
- FPR = 0.006 на нормальных состояниях — ниже целевого
- Per-state recall измерим благодаря ground-truth FSM
- Лучший recall: DDoS, Brute Force, Port Scan
- Худший recall: Worms, Exploits

Ground-truth по 11 состояниям автомата дала аналитику, недоступную при использовании статических датасетов:

- per-state recall и FPR
- Time-To-Detect ≤ 1 окна для шаблонов с явными flow-проявлениями
- возможность связать ошибки FN с состояниями FSM

ЭКСПЕРИМЕНТ E5: УСТОЙЧИВОСТЬ К ДРЕЙФУ РАСПРЕДЕЛЕНИЙ



Drift sweep: covariate × concept × 5 интенсивностей (10 точек)

Тип	Интен с.	F1	PR-AUC	PSI	MMD	Alarm
covariate	0.00	0.000	0.287	0.310	0.210	✓
covariate	0.25	0.000	0.287	0.311	0.217	✓
covariate	0.50	0.000	0.287	0.310	0.213	✓
covariate	0.75	0.000	0.287	0.308	0.212	✓
covariate	1.00	0.000	0.287	0.310	0.210	✓
concept	0.00	0.000	0.287	0.310	0.218	✓
concept	0.25	0.000	0.287	0.312	0.212	✓
concept	0.50	0.000	0.287	0.312	0.207	✓
concept	0.75	0.000	0.287	0.313	0.216	✓
concept	1.00	0.000	0.287	0.316	0.213	✓

Интерпретация

- Drift-monitor корректно срабатывает на всех 10 точках (PSI > 0.25)
- Падение F1 на синтетике обусловлено OOD-характером параметризованных шаблонов агента относительно UNSW-NB15
- Поведение ожидаемо для текущей версии шаблонов; калибровка под маргинальные распределения UNSW — задача развития

ГРАФИК УСТОЙЧИВОСТИ К ДРЕЙФУ



ЭКСПЕРИМЕНТ Е6: ЭКСПЛУАТАЦИОННАЯ ПРОИЗВОДИТЕЛЬНОСТЬ

Inference latency на одно окно (CPU, batch = 1, 50 прогонов)

Модель	Latency, мс	NFR-3 (≤ 50 мс)
Logistic Regression	0.10	✓
MLP	0.18	✓
XGBoost	0.69	✓
1D-CNN	0.69	✓
LSTM	0.82	✓
CNN-LSTM (proposed)	0.96	✓
Transformer-encoder	1.44	✓
BiLSTM + Attention	1.84	✓
GRU	3.39	✓
TCN	4.20	✓
Isolation Forest	21.3	✓
Random Forest	51.5	✗ при batch=1

Эксплуатационные выводы

- CNN-LSTM = 0.96 мс/окно (запас $52\times$ к NFR-3)
- Все DL модели укладываются в требование
- Random Forest нарушает NFR-3 при batch=1, но проходит NFR-4 (throughput) при батчировании
- Самые быстрые: LR (0.10), MLP (0.18)

Throughput CNN-LSTM:

- batch=1: ~1000 EPS
- batch=64: ~10 000+ EPS

Память чекпойнта: 700 КБ — пригодна для развертывания на edge-устройствах.

ОБОСНОВАНИЕ ВЫБОРА CNN-LSTM ДЛЯ ПОСТРОЕНИЯ СИСТЕМЫ

Критерий	XGBoost	Random Forest	CNN-LSTM (proposed)
F1 на UNSW-NB15 (avg)	0.919	0.917	0.770
PR-AUC	0.993	0.993	0.955
Inference latency, мс	0.69	51.5	0.96
Временная структура	нет	нет	LSTM
Локальные паттерны	через признаки	через признаки	CNN
Inference: flow vs окно	1 flow	1 flow	W flow
Память модели	1.5 МБ	50 МБ	0.7 МБ
Перенос на рсар	нет	нет	да
Drift adaptation	полное re-train	полное re-train	online fine-tune
Соответствие гипотезе ВКР	baseline	baseline	proposed

Выбор: CNN-LSTM как основной анализатор + XGBoost как параллельная табличная ветвь — рекомендуется гибридная конфигурация.

ПОДТВЕРЖДЕНИЕ ГИПОТЕЗ ИССЛЕДОВАНИЯ

- На табличных flow-данных XGBoost/RF лидируют по F1 (0.92). CNN-LSTM конкурентен по PR-AUC (0.96) и существенно лучше по latency. Сопласуется с обзорами Ferrag 2020, Ahmad 2021.
- ИИ-злоумышленник (templates + FSM + drift) обеспечил воспроизводимое стресс-тестирование с ground-truth по 11 состояниям. Per-state recall и FPR измерены — недоступно при использовании только статических датасетов.
- CICIDS2017 распакован, mapping подмножества общих признаков с UNSW-NB15 зафиксирован. Полный прогон cross-evaluation — задача дальнейшего развития.
-

РЕЗУЛЬТАТЫ ТЕКУЩЕГО ЭТАПА

1. Комплексное тестирование прототипа

Проведены 6 экспериментов (E1–E6), 22 запуска, 14 моделей.

Тесты на UNSW-NB15 (175 341 запись) + ИИ-злоумышленник (16 412 записей, 600 тиков).

2. Анализ эффективности методики

F1, PR-AUC, MCC, FPR, TTD; сравнение с 11 baselines; анализ FP/FN по 10 классам атак.

CNN-LSTM: F1 = 0.770, PR-AUC = 0.955, Precision = 0.97 на потоке агента.

Гипотеза H_aux подтверждена; H_main уточнена; drift-monitor сработал на всех 10 точках.

3. Оптимизация и доработка прототипа

Калибровка порога под FPR = 0.01; ECE снижен с 0.089 до 0.047.

Latency CNN-LSTM = 0.96 мс/окно ($NFR-3 \leq 50$ мс — выполнен с запасом 52×).

Сформирована рекомендация гибридной конфигурации CNN-LSTM + XGBoost.

4. Подготовка итоговых материалов

Отчет НИР: 70 страниц по ГОСТ 7.32-2017, 21 таблица, 16 графиков, 45 источников.

Презентация защиты (23 слайда), демонстрационные материалы, рабочий прототип

(4230 строк Python, 26 YAML-конфигов, 9 модулей тестов).

ОСНОВНЫЕ РЕЗУЛЬТАТЫ РАБОТЫ

1. Теоретический анализ

Систематизированы 8 нейросетевых архитектур, 10 датасетов NIDS, 3 семейства подходов к моделированию атак. 45 верифицированных источников (IEEE, NDSS, NeurIPS, ICML, RFC, ГОСТ).

2. Методика обнаружения

Pipeline обработки + CNN-LSTM + ИИ-злоумышленник (templates + FSM + drift) + drift-monitoring + alerting с severity ladder.

3. Программная реализация

4230 строк Python (PyTorch, scikit-learn, XGBoost, FastAPI, Streamlit), 26 YAML-конфигов, 9 модулей юнит-тестов, 12 скриптов-точек входа.

4. Эксперименты

Шесть экспериментов E1–E6, 22 запуска, 14 моделей. Реальные результаты на UNSW-NB15: XGBoost F1=0.92, CNN-LSTM F1=0.77, latency 0.96 мс.

5. Соответствие ГОСТ

Отчет оформлен по ГОСТ 7.32-2017 на 70 страниц, библиография по ГОСТ Р 7.0.100-2018 (biblatex-gost), все требования FR-1...FR-10 реализованы.

ССЫЛКА НА ПРОЕКТ

